实验数据

一、实验数据集

1.1 数据集基本信息

项目	内容
数据集名称	MUSDB18
来源	SIGSEP 社区标准数据集
曲目数量	150 首完整长度的多风格音乐曲目
总时长	约 10 小时
音乐风格	爵士、电子、摇滚、金属等多种类型
音频格式	44.1 kHz 采样率，立体声
数据划分	训练集 100 首 / 测试集 50 首

1.2 数据文件结构

每首歌曲包含以下文件：

```
歌曲名称/
├── mixture.wav      # 混合音频（所有轨道的叠加）
├── vocals.wav       # 人声参考音轨
├── drums.wav        # 鼓参考音轨
├── bass.wav         # 贝斯参考音轨
└── other.wav        # 其他伴奏参考音轨
```

1.3 数据集在平台中的使用

- **分离任务**：以 mixture.wav 作为输入，运行不同算法进行分离
- **客观指标计算**：以原始 stems（vocals/drums/bass/other）作为参考信号，与算法估计结果进行对比
- **主观评价**：评审员听辨分离结果并与参考音轨进行对比

二、评估指标体系

2.1 客观指标

BSS Eval 多源评估框架

将估计信号分解为四个分量：
$\hat{s} = s + e_{spat} + e_{interf} + e_{artif}$

其中：

- s — 目标源信号（参考）

- e_{spat} — 空间/滤波失真误差
- e_{interf} — 其他源泄漏引起的干扰误差
- e_{artif} — 算法引入的伪影误差

基于此定义的三个核心指标：

指标	全称	公式	衡量内容
SDR	Signal-to-Distortion Ratio	$10\log_{10}\frac{\|s\|^2}{\|e_{spat}+e_{interf}+e_{artif}\|^2}$	总体失真程度
SIR	Signal-to-Interference Ratio	$10\log_{10}\frac{\|s+e_{spat}\|^2}{\|e_{interf}\|^2}$	声部泄漏程度
SAR	Signal-to-Artifacts Ratio	$10\log_{10}\frac{\|s+e_{spat}+e_{interf}\|^2}{\|e_{artif}\|^2}$	算法伪影程度

补充指标

指标	全称	特点
SI-SDR	Scale-Invariant SDR	对整体增益缩放不敏感，衡量重建结构差异
ISR	Image-to-Spatial Ratio	BSS Eval v3 新增，衡量空间保真度

辅助创新指标：WOC/SOC

指标	全称	公式	用途
WOC	Waveform Overlap Consistency	$\frac{\sum_t \min(\tilde{a}(t),\tilde{\hat{a}}(t))}{\sum_t \max(\tilde{a}(t),\tilde{\hat{a}}(t))}$	时域重叠一致性
SOC	Spectrogram Overlap Consistency	$\frac{\sum_{f,t} \min(\tilde{A}(f,t),\tilde{\hat{A}}(f,t))}{\sum_{f,t} \max(\tilde{A}(f,t),\tilde{\hat{A}}(f,t))}$	时频域重叠一致性

其中 $\tilde{a}(t)$、$\tilde{\hat{a}}(t)$、$\tilde{A}(f,t)$、$\tilde{\hat{A}}(f,t)$ 均为 L1 归一化后的非负幅度表示。

2.2 主观评价维度

维度	英文	评分范围	评价内容
音质	Quality	1-5 分	整体清晰度、保真度、自然度
干扰抑制	Interference	1-5 分	目标声部中非目标声部的残留程度
伪影控制	Artifacts	1-5 分	算法引入的非自然成分（金属音、抖动、断续）

三、实验设计方案

3.1 客观指标对比实验

目的：比较四种算法在多声部音乐分离任务上的客观性能。

实验设置：

参数	设置
测试集	MUSDB18 测试集 50 首
对比算法	MDX23C、Demucs4HT、Band Split RoFormer、SCNet
评估指标	SDR、SIR、SAR、ISR、SI-SDR（逐 stem，四 stem 宏平均）
数据格式	统一为单声道、44.1kHz、PCM 16bit
统计汇报	Mean ± Std

实验流程：

1. 对每首测试歌曲，分别使用四种算法进行分离
2. 对每个分离结果，逐 stem 计算所有客观指标
3. 对每个算法，汇总所有 50 首歌曲的结果
4. 计算宏平均（Macro Average）作为算法整体性能
5. 以 Mean ± Std 形式汇报

3.2 主观评价实验

目的：评估四种算法分离结果的实际听感质量。

实验设置：

参数	设置
样本选择	从测试集随机抽取 10 首歌曲
评审员	5 名具有音频处理经验的专家
评价对象	4 种算法 × 4 个 stem（Vocals/Drums/Bass/Other）
评价维度	音质、干扰抑制、伪影控制（1-5 分李克特量表）
实验方法	双盲多激励听音测试（参考 MUSHRA 规范）
培训	正式实验前统一培训，明确评分标准

3.3 主客观关联分析实验

目的：验证 SOC 指标与主观音质评分之间的关联。

分析方法：

1. **Spearman 等级相关**：计算 SOC 与 Quality 评分的 Spearman ρ，并报告显著性水平 p

2. **排列检验（Permutation Test）**：通过随机打乱 SOC 标签，构造零分布，计算单侧 p 值
3. **分组检验**：将样本按 SOC 分位区间分组，比较最低分位与最高分位的主观评分差异

3.4 算法间显著性检验

目的：判断不同算法之间的性能差异是否具有统计显著性。

方法：配对 Wilcoxon 符号秩检验（含正态近似、打结修正、秩双列效应量），对同一歌曲的配对样本进行检验。

四、原始实验数据说明

所有实验原始数据通过 AudioLab 平台数据库进行持久化存储，包括：

1. **separation_tasks 表**：每个分离任务的算法、状态、文件路径、客观指标（SDR/SIR/SAR）、元数据（JSON 含 SI-SDR/SOC 等）
2. **scores 表**：每条主观评分记录，含评分人、任务、算法、stem、三维评分值
3. **stem_files 表**：分离结果文件路径
4. **audio_resources 表**：音频资源元数据

可通过平台以下 API 端点获取和导出实验数据：

- `GET /api/tasks/stats/objective` — 客观指标汇总
- `GET /api/tasks/stats/significance` — 显著性检验结果
- `GET /api/scores/stats/detailed` — 主观评分统计
- `GET /api/scores/stats/subjective-objective-points` — 主客观联合数据
- `GET /api/scores/stats/soc-quality-correlation` — SOC-音质相关分析
- `GET /api/tasks/export/csv` — CSV 数据导出
- `GET /api/tasks/export/paper-package` — 论文数据包打包下载（ZIP）