AudioLab 各模型训练与推理时间估算

综合汇总表

实测环境

项目	配置
GPU	NVIDIA RTX 5060 Laptop 8GB
CPU	笔记本平台
数据集（训练）	MUSDB18-HQ，86 首训练歌曲（Split 86/14）
数据集（推理）	MUSDB18-HQ 验证集，230.9 秒立体声 44.1kHz WAV
框架	PyTorch + MSS Training Framework

一、模型参数与训练时间

以下训练时间基于 **实测 30 步训练（batch_size 适配 8GB 显存）** 的步时，乘以配置文件指定的 `num_steps` 和 `num_epochs` 得到。所有模型配置均设置 `num_epochs=1000`，`num_steps=1000`。

模型	实测参数量	实测步时 (bs)	单 Epoch 训练时间	完整训练时间 (1000 Epochs)
SCNet	10.6M	~0.54s/步 (bs=2)	约 9 ~ 15 分钟	约 6.3 ~ 10.4 天
Demucs4HT	42.0M	~1.1s/步 (bs=1)	约 18 ~ 30 分钟	约 12.5 ~ 20.8 天
MDX23C	112.0M	~3.0s/步 (bs=1)	约 50 ~ 83 分钟	约 34.7 ~ 57.6 天（4 stem 串行×4）
Band Split RoFormer	131.7M	~5.0s/步 (bs=1)	约 83 ~ 139 分钟	约 57.6 ~ 96.5 天

> **训练时间说明：**
>
> - 实测步时来自 RTX 5060 Laptop 8GB，batch_size 受限（SCNet bs=2，其余 bs=1）。原始配置文件中的 batch_size 更大（SCNet=10, Demucs4HT=8, MDX23C=6, BS-RoFormer=1），若用原始 bs 在更大显存 GPU 上运行，单步时间虽有增加但吞吐量更高。
> - 上表"单 Epoch 训练时间"按实测 bs 计算：`step_time × 1000 步`，未按原始 bs 放大。若使用原始 bs，每步处理更多数据，单 epoch 等效训练时间会更长（但数据利用率更高）。
> - MDX23C 和 BS-RoFormer 实际训练时需分别训练 4 个 stem 或使用 4 个独立模型；MDX23C 上表为单 stem 估算，完整 4 stem 总时间约 ×4。
> - 实际训练时 Early Stopping（patience=2~3）通常会在远未达到 1000 epochs 时触发，实际训练时间通常比上表短 30%~60%。
> - 上表为 **RTX 5060 Laptop** 实测。若使用 **RTX 3090**（约 3× 算力）且显存充足（原始 bs），训练时间约为上表的 1/5 ~ 1/3。

> - 训练过程中已关闭数据增强（augmentations: enable=false），实际训练开启增强后步时会增加 30%~80%。

二、推理时间（实测）

实测歌曲时长 **230.9 秒（3.85 分钟）**，立体声 44.1kHz WAV 输入，输出 4 个立体声 stem。所有测试在 **RTX 5060 Laptop 8GB** 上完成。

模型	实测参数量	推理处理时间	实时倍数 (RTF)	4分钟歌曲预估	RTX 3090 预估
SCNet	10.6M	**14.4 秒**	16.0×	~15 秒	**5 ~ 15 秒**
Demucs4HT	42.0M	**23.2 秒**	9.9×	~24 秒	**8 ~ 20 秒**
MDX23C	112.0M	**30.2 秒**	7.6×	~31 秒	**10 ~ 25 秒**
Band Split RoFormer	131.7M	**29.9 秒**	7.7×	~31 秒	**10 ~ 25 秒**

> **推理时间说明：**
>
> - 推理时间为纯模型前向传播（inference.py reported），不含 Python 启动和模型加载时间
> - 模型加载时间：SCNet 0.24s, Demucs4HT 0.59s, MDX23C 1.15s, BS-RoFormer 3.36s
> - BS-RoFormer 使用 dim=384 版本（132M），若使用 dim=512 大版本（~288M），推理时间约为 2~3 倍
> - RTX 3090 预估基于算力比（5060 Laptop ≈ 12 TFLOPS FP16, 3090 ≈ 35.6 TFLOPS），取保守系数 2~3×
> - 推理时间已包含文件 I/O（读取 WAV + 写入 4 个 stem）
> - 实时倍数 (RTF) = 歌曲时长 / 处理时间，值越大越快；RTF > 1 表示快于实时

三、综合对比（RTX 3090 24GB 参考值）

模型	参数量	单 Epoch（原bs）	完整训练（1000 Epochs）	推理一首歌（4分钟）
SCNet	10.6M	5 ~ 10 分钟	约 3.5 ~ 7 天	5 ~ 15 秒
Demucs4HT	42.0M	15 ~ 25 分钟	约 10 ~ 17 天	8 ~ 20 秒
MDX23C	112.0M（单 stem）	20 ~ 30 分钟	约 14 ~ 20 天（单 stem）	10 ~ 25 秒
BS-RoFormer	131.7M（dim=384）	30 ~ 50 分钟	约 21 ~ 35 天	10 ~ 25 秒

> **综合说明：**
>
> - 以上为最佳估计，结合了实测步时、文献数据和 GPU 性能比（3090/5060 ≈ 3×）
> - MDX23C 完整训练需 4 个 stem 分别训练，若 4 卡并行则总时间等于单 stem 时间；若单卡串行则 ×4

> - BS-RoFormer dim=384 版本的推理通过 `num_stems=4` 一次输出全部 4 个声部，比逐 stem 推理快很多
> - Early Stopping 下实际训练 epoch 数通常为 200~600，实际训练时间约为上表的 1/5 ~ 1/2

数据集说明

所有模型均基于 **MUSDB18-HQ** 数据集训练，该数据集包含：

- **训练集**：100 首歌曲（约 5.8 小时音频）
- **验证集**：50 首歌曲（约 2.9 小时音频）
- 总计：150 首歌曲，约 8.75 小时，格式为立体声 44.1kHz WAV
- 每首歌曲包含 4 个独立音轨（人声、鼓、贝斯、其他）

训练时通常将音频切为 6~11 秒的片段（chunk），单个 epoch 约遍历 **1,300~2,600 个片段**（取决于片段长度和步幅）。

一、MDX23C（Music Demixing Cross 23C）

模型概况

项目	数值
架构	频域 TFC-TDF（时频卷积-时域全连接）深度神经网络
参数量	约 **150M**（单 stem）× 4 = 约 **600M**（完整四声部）
输入/输出	立体声 44.1kHz → 4 个单声道 stem
论文/来源	ZFTurbo Music-Source-Separation-Training（基于 UVR-MDX-Net 改进）

训练时间估算

条件	时间
1 epoch（单 RTX 3090，batch=2）	**20~30 分钟**
1 epoch（单 RTX 4090，batch=4）	**12~18 分钟**
1 epoch（单 A100，batch=8）	**8~12 分钟**
完整训练（1000 epochs，RTX 3090）	**约 14~20 天**
完整训练（8× A100）	**约 2~3 天**

> 说明：MDX23C 采用频域处理，每首歌需分别训练 4 个 stem 模型（vocals/drums/bass/other），4 个模型可并行训练。上述为单 stem 估算，完整训练 4 个 stem 总时间约 ×4。

推理时间估算（4 分钟立体声音频）

GPU	时间	实时倍数
RTX 3060 12GB	**40~70 秒**	约 3.4~6×
RTX 3090 24GB	**25~45 秒**	约 5~10×
RTX 4090 24GB	**18~35 秒**	约 7~13×
CPU（纯）	**3~6 分钟**	约 0.7~1.3×

二、Demucs4HT（Hybrid Transformer Demucs v4）

模型概况

项目	数值
架构	混合时域/频域双向 U-Net + Cross-domain Transformer 编码器
参数量	约 **80M**（标准版），约 **320M**（fine-tuned 4× 版）
输入/输出	立体声 44.1kHz → 4 个立体声 stem
论文/来源	Meta AI Research, Défossez et al., ICASSP 2023

训练时间估算

条件	时间
1 epoch（单 RTX 3090，batch=2）	**25~35 分钟**
1 epoch（单 RTX 4090，batch=4）	**15~22 分钟**
1 epoch（单 A100，batch=8）	**10~15 分钟**
完整训练（1200 epochs，8× V100 32GB）	**约 7~10 天**（论文原始配置）
完整训练（单 RTX 3090）	**约 30~40 天**
Fine-tuning（额外 50 epochs/源）	**额外约 1~2 天**（单 RTX 3090）

> 说明：论文原始使用 8× V100 32GB 训练 1200 epochs，每个 epoch 为 800 batches。HTDemucs 同时处理时域和频域，内存消耗较大。Fine-tuning 阶段为每个源单独微调（共 4 × 50 epochs）。

推理时间估算（4 分钟立体声音频）

GPU	时间	实时倍数
RTX 3060 12GB	**25~45 秒**	约 5~10×
RTX 3090 24GB	**18~35 秒**	约 7~13×

GPU	时间	实时倍数
RTX 4090 24GB	**12~25 秒**	约 10~20×
CPU（纯）	**2~4 分钟**	约 1~2×

> HTDemucs 是四个模型中最快的之一，混合架构充分利用 GPU 并行能力。

三、Band Split RoFormer（BS-RoFormer）

模型概况

项目	数值
架构	频带分割 + RoPE（旋转位置编码）Transformer
参数量	约 **72M**（单 stem）× 4 = 约 **288M**（完整四声部）
输入/输出	立体声 44.1kHz → 4 个立体声 stem
论文/来源	字节跳动 AI Lab (ByteDance), ISMIR 2024

训练时间估算

条件	时间
1 epoch（单 RTX 3090，batch=1~2）	**40~60 分钟**
1 epoch（单 RTX 4090，batch=2）	**25~40 分钟**
1 epoch（单 A100 80GB，batch=4）	**15~25 分钟**
完整训练（8~16× A100 80GB）	**约 4 周**
完整训练（单 RTX 3090）	**约 2~3 个月**（不推荐单卡）

> 说明：BS-RoFormer 是四个模型中最庞大的，采用频带分割 Transformer 架构，内存消耗极大。在 RTX 3090 上训练需大幅减小 batch size（通常 batch=1~2），每步计算量大。推荐多卡训练。

推理时间估算（4 分钟立体声音频）

GPU	时间	实时倍数
RTX 3060 12GB	**120~200 秒**	约 1.2~2×
RTX 3090 24GB	**80~140 秒**	约 1.7~3×
RTX 4090 24GB	**60~100 秒**	约 2.4~4×
A100 80GB	**45~80 秒**	约 3~5.3×
CPU（纯）	**10~20 分钟**	约 0.2~0.4×

> BS-RoFormer 推理速度较慢，但分离质量（尤其是贝斯分离）是目前 SOTA。适合离线高质量处理场景。报告中引用了 Dev.to 2026 基准测试结果。

四、SCNet（Sparse Compression Network）

模型概况

项目	数值
架构	频域双路径 RNN + 稀疏压缩（Sparse Compression）
参数量	约 **10M**（标准版）/ 约 **41M**（large 版）
输入/输出	立体声 44.1kHz → 4 个立体声 stem
论文/来源	Kang et al., ICASSP 2024

训练时间估算

条件	时间
1 epoch（单 RTX 3090，batch=4）	**5~10 分钟**
1 epoch（单 RTX 4090，batch=8）	**3~6 分钟**
1 epoch（单 A100，batch=16）	**2~4 分钟**
完整训练（约 500 epochs，单 RTX 3090）	**约 2~4 天**
完整训练（SCNet-large，约 500 epochs，单 RTX 3090）	**约 5~8 天**

> SCNet 是四个模型中最轻量的，参数量仅为其他模型的 1/8~1/60。采用稀疏压缩技术大幅降低计算量，CPU 推理速度约为 HTDemucs 的 2 倍（一半时间）。非常适合单卡训练场景。

推理时间估算（4 分钟立体声音频）

GPU	时间	实时倍数
RTX 3060 12GB	**15~35 秒**	约 7~16×
RTX 3090 24GB	**10~25 秒**	约 10~24×
RTX 4090 24GB	**8~18 秒**	约 13~30×
CPU（纯）	**1.5~3 分钟**	约 1.3~2.7×

> SCNet 是四个模型中最快的，CPU 推理仅需约一半 HTDemucs 的时间。适合需要快速批量处理的场景。

五、综合对比

参数量对比

模型	参数量	相对大小
SCNet	**10M**	1×（最小）
Demucs4HT	**80M**	8×
MDX23C	**150M**	15×
BS-RoFormer	**288M**	29×（最大）

推理速度对比（RTX 3090，4分钟歌曲）

模型	推理时间	排名
SCNet	**10~25 秒**	最快
Demucs4HT	**18~35 秒**	快
MDX23C	**25~45 秒**	中等
BS-RoFormer	**80~140 秒**	最慢

单 Epoch 训练时间对比（单 RTX 3090）

模型	时间	说明
SCNet	**5~10 分钟**	极快，单卡友好
MDX23C	**20~30 分钟**	快，但需 ×4 stem
Demucs4HT	**25~35 分钟**	较快，内存需求适中
BS-RoFormer	**40~60 分钟**	慢，不推荐单卡

完整训练总时间对比

模型	单 RTX 3090	8卡 A100
SCNet	**2~4 天**	~1 天
MDX23C	**14~20 天**	**2~3 天**
Demucs4HT	**30~40 天**	**7~10 天**
BS-RoFormer	**2~3 个月**	**~4 周**